INFORME TÉCNICO: PREDICCIÓN DE INTENCIÓN DE COMPRA ONLINE

Asignatura: Tecnologías Emergentes (ISO46B)

Grupo 5 — Dataset 3

Entrega: 19/10/2026

1. Planteamiento

El sistema predice si una sesión de comercio electrónico terminará en compra (Revenue = True). El usuario del sistema es el equipo de marketing o de conversión: necesita decidir, durante la visita, si vale la pena ofrecer un incentivo (cupón) antes de que la persona cierre la pestaña.

La predicción se hace con datos de la sesión en curso: páginas vistas, tiempos, tipo de visitante, mes, fin de semana, tasas de rebote/salida y valor de páginas ya visitadas. No se usa información posterior al checkout.

Error más costoso: falso negativo (iba a abandonar y no se detecta) implica una venta perdida; el falso positivo gasta un descuento en alguien que ya iba a pagar. En este negocio la venta perdida suele pesar más, por eso no nos guiamos por accuracy. La métrica principal es F1 de la clase compra, complementada con recall, precision y PR-AUC. El umbral se elige en validación maximizando F1.

2. Datos y exploración

Fuente: Sakar, C. Okan; Kastro, Yomi (2018). Online Shoppers Purchasing Intention Dataset. UCI Machine Learning Repository. DOI 10.24432/C5F88Q. 12 330 sesiones, 17 atributos + Revenue.

Calidad: no hay nulos. La clase positiva es aproximadamente 15,5 % (desbalance). Month usa la etiqueta June (no Jun). Enteros como región o tipo de tráfico se tratan como numéricos.

Fuga: no se usa el resultado de la compra como entrada. PageValues es el valor medio de páginas ya visitadas en la sesión; se conoce en el momento de decidir y se conserva. El chatbot no pregunta esa variable: rellena la mediana de entrenamiento cuando el usuario no la aporta.

Partición estratificada 70 % / 15 % / 15 %. StandardScaler y OneHotEncoder se ajustan solo con entrenamiento (src/datos.py).

3. Modelado

Modelo	Idea
Trivial	Clase mayoritaria (siempre “no compra”).
Simple	Regresión logística con class_weight=balanced.
Red v1	MLP, una capa oculta (32).
Red v2	MLP, dos capas (64-32) y L2 (alpha=0.01).

La línea trivial deja accuracy 0,845 y F1 0: demuestra que accuracy no sirve. En validación, con umbral propio, la regresión logística ganó a las dos redes (F1 0,631 vs 0,610 y 0,566). Se promueve la logística: un modelo más simple y mejor en la métrica acordada.

4. Evaluación y versionado

Para cada modelo se busca un umbral en [0.10, 0.90] que maximice F1 en validación. El ganador se elige solo con esas métricas. El conjunto de prueba se mira una vez, solo para el promovido.

Resultado de validación (F1): trivial 0,00 (umbral irrelevante); logística 0,631 (umbral 0,55); red v1 0,610 (0,21); red v2 0,566 (0,26).

Prueba única del ganador: F1 0,640; precision 0,578; recall 0,717; accuracy 0,875; PR-AUC 0,622.

Cada versión tiene ficha JSON en modelos/. El ganador se copia a modelo_produccion.pkl y el umbral a umbral.json.

5. API

FastAPI carga el modelo promovido, el preprocesador y el umbral. GET /health indica si el modelo está en memoria. POST /predecir valida los 17 campos (src/preprocesamiento_api.py): tipos, rangos, mes y tipo de visitante. Error de negocio: HTTP 400. Si falta el modelo: HTTP 503. Responde clase, probabilidad de compra y umbral usado.

Durante la revisión manual, /health respondió correctamente, una entrada válida obtuvo HTTP 200 y una entrada con ProductRelated negativo obtuvo HTTP 400 con un mensaje de validación.

6. Chatbot

Flujo en docs/flujo_chatbot.png. Recolecta slots (visitante, páginas de producto, minutos, fin de semana, mes), completa el resto con medianas/modas de train, llama a la API y habla en lenguaje no técnico: cupón si predice abandono, o invitación a caja si predice compra. Fallback a los 3 intentos inválidos. Palabras ayuda, humano, asesor o salir derivan a una persona. Si la API no responde, también deriva.

Durante la revisión, el comando ayuda mostró la transferencia a un asesor y una conversación normal completó la captura de datos y presentó una probabilidad estimada de compra baja (20,25 %).

7. Limitaciones y ética

El modelo usa región, sistema operativo y tipo de tráfico, que pueden correlacionar con contexto socioeconómico. No usamos sexo ni salud. Un cupón automático puede resultar inequitativo si el error no es uniforme entre grupos (por ejemplo, visitante nuevo frente a recurrente): conviene medir recall por VisitorType y Weekend en un trabajo futuro.

PageValues=0 por defecto en el chatbot puede subestimar a quien ya vio páginas de alto valor. Los datos son de 2018 y un sitio concreto; no se deben tratar como universales. El sistema no sustituye a un asesor en quejas o pagos.

8. Contribución de cada integrante

Integrante	Contribución realizada
Carlos Alexis Romero Romani	Responsable de las etapas E1, E2 y E3: planteamiento del problema, preparación y exploración de los datos, y desarrollo de los modelos de aprendizaje automático.
Anderson Raul Paucar Taipe	**Responsable de la etapa E4: evaluación, comparación, selección y versionado de los modelos.**
Richard Torres Areche	Responsable de la etapa E5: desarrollo de la API, validación de entradas y pruebas de los endpoints.
Joel Angelo Paucar Marca	Responsable de la etapa E6: desarrollo del chatbot, integración con la API y diseño del flujo conversacional.